

Progetto di Ingegneria della
Conoscenza

Sistema Adattivo Terapeutico per l'Ottimizzazione del Sonno

Giovanni_Vendola, 798328, g.vendola9@studenti.uniba.it

Pierluca_Amato 799533, p.amato4@studenti.uniba.it

<[PierluvaAmaro/ICON-project-SleepOptimizer](#) >

AA 2025-26

Indice

1. Introduzione.....	4
Sommario.....	5
Elenco degli argomenti di interesse.....	6
2. Dataset e Analisi dei Dati.....	7
Sleep Health & Daily Performance Dataset.....	7
Origine e validazione clinica.....	7
Struttura del dataset.....	7
Statistiche principali.....	9
Preprocessing e Bilanciamento.....	10
Il problema dello sbilanciamento clinico.....	10
Bilanciamento e contrasto statistico.....	10
Statistiche comportamentali per classe target.....	10
3. Knowledge Base Prolog.....	12
Sommario.....	12
Strumenti utilizzati.....	13
Decisioni di progetto.....	14
Generazione dell'A-Box e Normalizzazione Sintattica.....	14
Regola 1: Misallineamento Circadiano.....	14
Regola 2: Tossicità Comportamentale Pre-Sonno.....	15
Regola 3: Stress Fisiologico Combinato.....	15
Estrazione Unificata e Failure-Driven Loop.....	16
Valutazione Formale e di Runtime.....	17
4. Apprendimento non supervisionato (k-means).....	18
Sommario.....	18
Strumenti utilizzati.....	19
Decisioni di progetto.....	19
Valutazione dei Risultati.....	20
5. Apprendimento supervisionato (Machine Learning).....	21
Sommario.....	21
Strumenti utilizzati.....	22
Decisioni di progetto.....	23
Separazione dei Dataset e Ingegneria delle Feature.....	23

Pipeline di Preprocessing Automatizzata.....	23
Strategia di Validazione e Metriche di Prestazione.....	23
Valutazione Sperimentale	24
Confronto tra Modelli (Metriche).....	25
Si osserva come l'impatto della Knowledge Base sia inversamente proporzionale alla complessità intrinseca del modello:.....	25
Analisi dell'Importanza delle Feature.....	28
6.Motore Probabilistico: Rete Bayesiana (BBN)	29
Sommario	29
Strumenti utilizzati	29
Decisioni di progetto	30
Struttura del Grafo Diretto Aciclico (DAG).....	30
Discretizzazione delle Variabili Continue.....	31
Apprendimento dei Parametri e Analisi sullo Stimatore BDeu.....	31
Inferenza a RunTime: Variable Elimination.....	31
Valutazione e Analisi dei Grafici	32
Validazione Topologica del Modello.....	32
Scenario 1: Inferenza Predittiva (What-If Analysis).....	33
Scenario 2: Inferenza Diagnostica (Ragionamento all'Indietro).....	34
7. Ricerca Euristica: Algoritmo A*	36
Sommario	36
Strumenti Utilizzati	37
Decisioni di Progetto	38
Spazio degli Stati.....	38
Funzione di Costo Reale $g(n)$	39
Euristica Ammissibile $h(n)$	39
Goal Test Ibrido (Interazione Neuro-Simbolica).....	39
Valutazione	40
Verifica delle Proprietà Formali.....	40
Casi di Test Funzionali (Log di Esecuzione).....	41
Parametri e Soglie.....	43
8. Conclusioni	44
Sviluppi Futuri e Limitazioni Attuali.....	46
Sviluppi Futuri.....	46
Limitazioni Attuali.....	46
9. Riferimenti Bibliografici	46

Capitolo 1

1. Introduzione

Il sonno rappresenta uno dei pilastri fondamentali dell'omeostasi biologica e del benessere psicofisico dell'essere umano. Negli ultimi decenni, l'incidenza dei disturbi del sonno – tra cui l'insonnia cronica, le apnee ostruttive del sonno (OSA) e le alterazioni del ritmo circadiano – ha registrato un incremento critico nelle società contemporanee. Tali patologie non si configurano semplicemente come disordini isolati, ma agiscono come catalizzatori per l'insorgenza di co-morbidità severe, tra cui disfunzioni cardiovascolari, alterazioni metaboliche (obesità, diabete di tipo 2), deficit cognitivi e disturbi della sfera emotiva.

La genesi dei disturbi del sonno è intrinsecamente multifattoriale e deriva da una complessa interazione tra variabili biologico-strutturali e determinanti comportamentali ed ambientali. Fattori legati allo stile di vita, quali l'abuso quantitativo e temporale di sostanze neurostimolanti (caffaina), il consumo serale di alcolici, la sedentarietà e l'iper-esposizione cronica alla luce blu dei dispositivi elettronici nelle ore antecedenti il riposo (*screen time*), si combinano con parametri fisiologici individuali (come l'Indice di Massa Corporea o BMI) e micro-ambientali (la

temperatura della camera da letto), creando un ecosistema disfunzionale che mina la qualità e la durata del sonno.

In questo scenario, la medicina moderna si trova ad affrontare una duplice sfida: da un lato, la necessità di formulare diagnosi accurate in regime di incertezza e scarsità di dati clinici oggettivi a lungo termine; dall'altro, l'urgenza di strutturare percorsi terapeutici personalizzati che non si limitino alla somministrazione farmacologica, ma che intervengano in modo mirato e sostenibile sulle abitudini comportamentali del paziente (la cosiddetta *igiene del sonno*).

Sommario

Il sistema si configura come un *Knowledge-Based System (KBS)* centralizzato e multi-paradigma, progettato per operare come un Agente Intelligente nel dominio della medicina computazionale del sonno. La complessa natura dei disturbi del sonno richiede un sistema che non si limiti alla mera computazione statistica, ma che sia in grado di manipolare conoscenza esplicita, ragionare in regime di incertezza e pianificare azioni correttive. Per fare ciò, l'architettura del KBS non è concepita come un blocco monolitico, ma come un ecosistema di moduli interdipendenti e disaccoppiati, ognuno deputato a risolvere una specifica sotto-istanza del problema clinico.

L'integrazione dei moduli all'interno del KBS segue una pipeline logico-funzionale rigorosa:

- *Il sistema di ragionamento (Prolog)*: La conoscenza deterministica e assiomatica del dominio clinico (linee guida standard, controindicazioni assolute, vincoli biologici) è codificata mediante la logica dichiarativa del primo ordine. Questo modulo funge da barriera semantica iniziale, validando i dati del paziente rispetto a vincoli rigidi e deducendo stati di rischio preliminari non soggetti a computazione probabilistica.
- *La Stratificazione Empirica (Unsupervised Learning)*: Il KBS integra moduli di apprendimento non supervisionato (Clustering K-Means) per analizzare le 100.000 istanze del dataset ed estrarre la struttura latente della popolazione. Questo modulo fornisce al sistema la capacità di categorizzare autonomamente i pazienti in "fenotipi

comportamentali", identificando le cause radice macroscopiche dei disordini (es. cluster di soggetti con insonnia termico-ambientale rispetto a quelli con insonnia da abuso tecnologico).

- *La predizione (Supervised Learning)*: Attraverso modelli ensemble di classificazione (Random Forest/SVM etc...), il KBS acquisisce competenze predittive basate sui dati. L'aspetto cruciale di questa integrazione risiede nell'ottimizzazione tramite la metrica di *Log-loss*: il classificatore non emette una diagnosi binaria rigida, ma restituisce una probabilità calibrata della classe *Healthy*, che serve al sistema per quantificare matematicamente lo stato di salute generale di una configurazione di abitudini.
- *La Spiegabilità Causale (Rete Bayesiana)*: Per superare i limiti di opacità del Machine Learning, il KBS implementa una Rete Bayesiana (BBN). Attraverso algoritmi di inferenza probabilistica (*Variable Elimination*), questo modulo modella le relazioni di causa-effetto tra le variabili di igiene del sonno discretizzate, fornendo al sistema (e al clinico) un livello di spiegabilità sul *perché* un determinato profilo presenti un rischio patologico (*Explainable AI*).
- *Il Risolutore di Problemi (Pianificazione A*)*: L'intelligenza del KBS si traduce in azione terapeutica nel modulo di ricerca euristica. L'algoritmo A* esplora lo spazio degli stati continuo definito dalle 8 leve comportamentali del paziente. L'integrazione è qui massima: il pianificatore non utilizza una funzione obiettivo statica, ma interroga dinamicamente i modelli probabilistici e predittivi (ML/BBN) come oracoli di *Goal Test*. Il percorso terapeutico ottimale emerge così come la sequenza di azioni a costo psicofisico minimo che sposta il paziente verso una configurazione di variabili la cui probabilità di salute supera la soglia di sicurezza validata dai modelli sub-simbolici.

Elenco degli argomenti di interesse

Lo sviluppo del progetto ha permesso di approfondire e implementare le seguenti competenze fondamentali, dettagliate nei successivi capitoli della documentazione:

1. *Rappresentazione della Conoscenza e Logica del Primo Ordine*: Modellazione ontologica del dominio medico mediante clausole di Horn e fatti in linguaggio Prolog. Implementazione di un motore inferenziale deduttivo per la verifica dei vincoli clinici e la validazione semantica dei profili.
2. *Apprendimento Automatico Non Supervisionato*: Estrazione di pattern nascosti e segmentazione della popolazione tramite l'algoritmo K-Means. Utilizzo di metriche matematiche come l'Elbow Method (Inerzia) per l'ottimizzazione e la validazione del numero ottimale di cluster.
3. *Apprendimento Automatico Supervisionato*: Addestramento di modelli predittivi non lineari (Random Forest / XGBoost) su dataset tabulari ad alta cardinalità. Analisi

approfondita delle metriche di classificazione (Accuracy, Precision, Recall, F1-Score) con focus specifico sulla calibrazione probabilistica mediante la funzione di costo Cross-Entropy (*Log-loss*).

4. *Ragionamento Probabilistico e Grafi Causali*: Progettazione e implementazione di una Rete Bayesiana (BBN) tramite modelli grafici diretti. Definizione delle Tabelle di Probabilità Condizionata (CPT) estratte empiricamente dai dati e applicazione dell'algoritmo di Variable Elimination per l'inferenza esatta in regime di incertezza.
5. *Ricerca Euristica nello Spazio degli Stati*: Sviluppo nativo dell'algoritmo di ricerca informata A* applicato a uno spazio degli stati multidimensionale continuo. Progettazione di funzioni di transizione di stato coerenti (azioni terapeutiche), modellazione dei costi di cammino $g(n)$ basati sull'aderenza clinica, e formulazione di una funzione euristica $h(n)$ ammissibile e consistente basata sulla distanza Euclidea pesata e normalizzata.

Capitolo 2

2. Dataset e Analisi dei Dati

Per lo sviluppo, la fase di reperimento dei dati è stata lineare grazie all'utilizzo dello *Sleep Health & Daily Performance Dataset*, disponibile pubblicamente sulla piattaforma Kaggle. Questo database si è rivelato ottimale per l'addestramento del nostro sistema poiché unisce in un unico snapshot sia i parametri fisiologici individuali sia le abitudini comportamentali legate all'igiene del sonno.

Sleep Health & Daily Performance Dataset

Origine e validazione clinica

Il dataset di base utilizzato per il progetto è lo *Sleep Health & Daily Performance Dataset*, reperito tramite la piattaforma Kaggle. A differenza dei dataset puramente osservazionali, questa fonte contiene 100.000 record sintetici progettati esplicitamente per l'analisi completa della salute del sonno e la predizione del rischio.

Il dato fondamentale è che le distribuzioni, le correlazioni e i profili occupazionali sono *research-grounded*, ovvero rigorosamente calibrati su fonti istituzionali sottoposte a peer-review, tra cui il CDC National Health Interview Survey (2024), gli studi della Sleep Foundation e il Framingham Heart Study. Questo approccio garantisce la privacy dei soggetti reali pur mantenendo relazioni statistiche che specchiano fedelmente i pattern del mondo reale.

Struttura del dataset

Ogni record del dataset cattura uno snapshot giornaliero completo del paziente. Le variabili sono state filtrate per selezionare le 8 feature comportamentali e fisiologiche determinanti per il dominio del problema:

Campo	Tipo	Descrizione	Valori esempio
bmi	float	Indice di Massa Corporea (kg/m) ²	22.5, 28.4, 31.0
caffeine	int	Caffeina totale assunta nelle 24h (mg)	0, 150, 300
steps	int	Attività fisica in passi giornalieri	3000, 8500, 12000
sleep	float	Durata del sonno notturno (ore)	4.5, 6.0, 7.5
caffeine_mg_before_bed	int	Caffeina nelle 4 ore pre-sonno (mg)	0, 40, 80
alcohol_units_before_bed	int	Unità alcoliche assunte a cena/sera	0, 1, 3

<code>screen_time_before_bed_mins</code>	int	Uso di schermi/luce blu pre-sonno (minuti)	15, 60, 120
<code>room_temperature_celsius</code>	float	Temperatura ambientale della camera (°C)	18.5, 22.0, 25.5
<code>sleep_disorder_risk</code>	string	Variabile Obiettivo (Target Class)	Healthy, Mild, Moderate, Severe

Statistiche principali

L'elevata cardinalità del dataset lo rende ideale per l'addestramento di modelli di classificazione Ensemble e per l'apprendimento dei parametri delle Tabelle di Probabilità Condizionata (CPT) della Rete Bayesiana.

Metrica	Valore
Righe totali (snapshot giornalieri)	100.000
Feature predittive utilizzate	8

Classi diagnostiche target	4
Pazienti con BMI nel range normopeso	42.500 (42.5%)
Pazienti con disturbi di livello Severe	18.200 (18.2%)

Preprocessing e Bilanciamento

Il problema dello sbilanciamento clinico

Un problema critico nei dataset medici e di farmacovigilanza è lo sbilanciamento strutturale delle classi. Spesso i record clinici si concentrano sui casi patologici evidenti (soggetti sintomatici), lasciando sottorappresentata la classe dei soggetti completamente sani. Addestrare un modello di Machine Learning su un dataset sbilanciato non permette all'algoritmo di discriminare correttamente i profili sicuri, producendo un classificatore degenere incline ai falsi positivi.

Bilanciamento e contrasto statistico

Per risolvere questo squilibrio e fornire un segnale discriminativo netto ai modelli, è stata implementata la seguente tecnica: per le classi sottorappresentate (in particolare il target *Healthy*), la pipeline ha generato record sintetici alterando deliberatamente (in senso positivo) le variabili di igiene del sonno di casi patologici.

Azzerando l'alcol serale, portando lo screen time sotto la soglia critica dei 30 minuti e imponendo temperature ambientali ottimali (intorno ai 18.5°C), è stato creato un netto contrasto statistico tra i soggetti sani e quelli patologici. Questo contrasto è fondamentale per permettere

all'algoritmo A* di percepire un differenziale di rischio matematico concreto quando applica le azioni terapeutiche che simulano questi miglioramenti comportamentali.

Statistiche comportamentali per classe target

La tabella seguente evidenzia il gradiente statistico appreso dai modelli (Random Forest e BBN) a valle del bilanciamento, confermando l'assunto medico che abitudini disfunzionali correlano con classi di rischio progressivamente più severe:

Metrica (Media)	Target: Healthy	Target: Moderate	Target: Severe
BMI medio	22.8	27.5	31.2
Screen time pre-sonno	25 min	85 min	140 min
Caffeina serale	5 mg	45 mg	90 mg
Ore di sonno	7.8 h	5.5 h	4.2 h

Passi giornalieri	9500	5200	3100
-------------------	------	------	------

La divergenza estrema nei parametri come lo *screen time* e l'attività fisica (passi) costituisce il segnale predominante sfruttato dal Random Forest per isolare i cluster sani, ed è del tutto coerente con la letteratura medica che individua nell'igiene del sonno comportamentale uno dei fattori più robusti per prevenire l'insonnia.

Capitolo 3

3. Knowledge Base Prolog

Sommario

La Knowledge Base (KB) costituisce la componente simbolica, deterministica e deduttiva del sistema. All'interno dell'architettura neuro-simbolica del framework, essa assolve a un duplice obiettivo fondamentale: da un lato rappresenta formalmente l'ontologia clinica e comportamentale legata all'igiene del sonno; dall'altro opera come un modulo di vincoli rigidi (*hard constraints*). Questi vincoli impongono regole di sicurezza assolute sulle combinazioni di azioni terapeutiche raccomandate, garantendo proprietà che né i modelli di Machine Learning né le Reti Bayesiane possono assicurare intrinsecamente a causa della loro natura puramente statistica e probabilistica.

La rappresentazione della conoscenza si basa sul formalismo delle clausole definite della logica del primo ordine, la cui esecuzione ed inferenza sono affidate all'ambiente di runtime SWI-Prolog. Coerentemente con i paradigmi dei sistemi basati su conoscenza, la KB è strutturata separando nettamente la componente intensionale (T-Box, *Terminology Box*) da quella estensionale (A-Box, *Assertion Box*):

- A-Box (Componente Estensionale): È rappresentata dal file dei fatti `fatti_pazienti.pl`, generato programmaticamente dallo script Python `data_pipeline.py`. Questo file mappa i record di Kaggle in asserzioni Prolog strutturate secondo il predicato a 15 argomenti:

paziente(ID, Eta, Genere, Occupazione, BMI, OreSonno, QualitaSonno, Caffaina, Alcol, ScreenTime, Esercizio, Battito, ShiftWork, Cronotipo, Rischio).

- T-Box (Componente Intensionale): È implementata nel file *kb.pl*, contenente gli assiomi e le regole logiche di inferenza che definiscono le relazioni latenti del dominio clinico e comportamentale (misallineamento circadiano, tossicità pre-sonno e stress fisiologico). La T-Box importa dinamicamente l'A-Box tramite la direttiva nativa :-
consult('../data/fatti_pazienti.pl').

Il modulo di estrazione converte le variabili quantitative del dataset in stringhe atomiche normalizzate Prolog (es. convertendo in minuscolo, eliminando caratteri speciali e applicando lo *slugging* con underscore), assicurando la piena conformità con i requisiti sintattici del linguaggio.

Strumenti utilizzati

Strumento	Ruolo nel Sistema
SWI-Prolog (>= 9.x)	Runtime Prolog ufficiale incaricato del caricamento delle clausole, dell'esecuzione della risoluzione SLD e del backtracking nativo per le query inferenziali.
Python & Pandas	Gestione della pipeline di ingegneria dei dati (data pipeline.py) per il caricamento del CSV, la normalizzazione sintattica e la formattazione dei fatti Prolog.
Failure-Driven Loop	Costrutto logico ricorsivo nativo sfruttato in Prolog per effettuare l'esportazione relativa ai batch dei dati arricchiti in tempo lineare senza saturare la memoria.

Decisioni di progetto

Generazione dell'A-Box e Normalizzazione Sintattica

Una delle decisioni ingegneristiche fondamentali risiede nel modulo di pre-processing in *data_pipeline.py*. Poiché la sintassi Prolog impone che le costanti atomiche (atomi) inizino rigorosamente con una lettera minuscola e non contengano spazi, la pipeline Python esegue una sanificazione preventiva sulle stringhe del dataset (quali professioni, genere e cronotipo):

```
df.columns = df.columns.str.lower().str.replace(' ', '_')
for col in categorical_cols:
    df[col] = df[col].astype(str).str.lower().str.replace(' ', '_')
```

I dati vengono poi iterati e trascritti sequenzialmente su file di testo per essere letti nativamente dal compilatore Prolog come fatti strutturati.

Regola 1: Misallineamento Circadiano

Questo predicato individua i conflitti biologici tra i turni lavorativi del soggetto (ShiftWork = 1) e il suo cronotipo naturale (morning, evening, neutral). Per ottimizzare l'esecuzione ed evitare computazioni ridondanti, la regola sfrutta l'operatore di cut (!), che blocca i rami di backtracking alternativi non appena viene soddisfatta la prima condizione utile:

```
misallineamento_circadiano(ID, severo) :-
    paziente(ID, _, _, _, _, _, _, _, _, _, _, 1, morning, _), !.
misallineamento_circadiano(ID, severo) :-
    paziente(ID, _, _, _, _, _, _, _, _, _, _, 1, evening, _), !.
misallineamento_circadiano(ID, moderato) :-
    paziente(ID, _, _, _, _, _, _, _, _, _, _, 1, neutral, _), !.
misallineamento_circadiano(ID, assente) :-
    paziente(ID, _, _, _, _, _, _, _, _, _, _, 0, _, _).
```

Regola 2: Tossicità Comportamentale Pre-Sonno

Modella l'impatto combinato di abitudini serali disfunzionali (assunzione di caffeina, unità alcoliche ed esposizione alla luce blu dei dispositivi elettronici). La regola implementa un **sistema a punteggio parziale (scoring)**, in cui ogni comportamento è pesato e discretizzato in un range [0, 2]. La somma algebrica (Totale is SC + SA + SS) mappa infine il paziente in una classe di tossicità qualitativa tramite costrutti condizionali ->:

```
score_caffeina(Caffeina, 2) :- Caffeina > 100, !.  
score_caffeina(Caffeina, 1) :- Caffeina > 0, !.  
score_caffeina(_, 0).  
  
score_alcol(Alcol, 2) :- Alcol > 2, !.  
score_alcol(Alcol, 1) :- Alcol > 0, !.  
score_alcol(_, 0).  
  
score_screen(Screen, 2) :- Screen > 60, !.  
score_screen(Screen, 1) :- Screen > 20, !.  
score_screen(_, 0).  
  
tossicita_presonno(ID, Livello) :-  
    paziente(ID, _, _, _, _, _, Caffeina, Alcol, Screen, _, _, _, _, _),  
    score_caffeina(Caffeina, SC),  
    score_alcol(Alcol, SA),  
    score_screen(Screen, SS),  
    Totale is SC + SA + SS,  
    (Totale >= 4 -> Livello = critica ;  
     Totale >= 2 -> Livello = alta ;  
     Livello = bassa).
```

Regola 3: Stress Fisiologico Combinato

Rappresenta il predicato più articolato per via dell'incrocio multidimensionale dei dati. Essa integra variabili biometriche oggettive (battito cardiaco a riposo e BMI) con lo stile di vita (ore di sonno totali e giorni di esercizio fisico). L'attività fisica regolare funge da attenuatore dello

stress (assegnando punteggio 0), mentre un profilo sedentario aggrava il quadro clinico. Un totale ≥ 5 classifica lo stress come critico:

```
score_cardio(Battito, 2) :- Battito > 75, !.  
score_cardio(Battito, 1) :- Battito > 65, !.  
score_cardio(_, 0).  
  
score_peso(BMI, 2) :- BMI > 29.9, !.    % Obesità  
score_peso(BMI, 1) :- BMI > 24.9, !.    % Sovrappeso  
score_peso(_, 0).  
  
score_attivita(Esercizio, 0) :- Esercizio >= 4, !. %L'attività mitiga lo  
stress  
score_attivita(Esercizio, 1) :- Esercizio >= 1, !.  
score_attivita(_, 2). %La sedentarietà penalizza  
  
stress_fisiologico(ID, Livello) :-  
    paziente(ID, _, _, BMI, OreSonno, _, _, _, Esercizio, Battito, _,  
    _, _),  
    score_cardio(Battito, SC),  
    score_peso(BMI, SP),  
    score_attivita(Esercizio, SA),  
    (OreSonno < 6.0 -> SO = 2 ; OreSonno < 7.0 -> SO = 1 ; SO = 0),  
    Totale is SC + SP + SA + SO,  
    (Totale >= 5 -> Livello = critico ; Totale >= 2 -> Livello = medio ;  
    Livello = normale).
```

Estrazione Unificata e Failure-Driven Loop

Al fine di consentire l'esportazione batch delle nuove feature verso l'ecosistema Python, è stato definito il predicato `estrai_feature_latenti/4`. Questo viene inserito all'interno di un Failure-Driven Loop nel predicato `genera_dataset_arricchito/0`. Sfruttando il fallimento indotto dal predicato integrato `fail`, il motore di inferenza è costretto a ciclare per backtracking su tutti i 100.000 fatti paziente, scrivendo in streaming sul file CSV senza allocare frame nello stack di memoria e mantenendo l'occupazione di memoria costante ($O(1)$ nello spazio di esecuzione):

```
estrai_feature_latenti(ID, Mismatch, Tossicita, Stress) :-  
    misallineamento_circadiano(ID, Mismatch),  
    tossicita_presonno(ID, Tossicita),  
    stress_fisiologico(ID, Stress).
```

```

genera_dataset_arricchito :-
    open('../data/sleep_health_enriched.csv', write, Stream),
    write(Stream,
'person_id,misallineamento_circadiano,tossicita_presonno,stress_fisiologico
\n'),
    (
        paziente(ID, _, _, _, _, _, _, _, _, _, _, _),
        estrai_feature_latenti(ID, Mismatch, Tossicita, Stress),
        format(Stream, '~w,~w,~w,~w\n', [ID, Mismatch, Tossicita, Stress]),
        fail
    );
    true
),
close(Stream).

```

Valutazione Formale e di Runtime

La validazione del modulo logico si basa sulla verifica delle proprietà di correttezza (soundness) e completezza (completeness) logica, garantite matematicamente dal meccanismo della risoluzione SLD applicata alle clausole Horn nell'Assunzione di Mondo Chiuso (CWA).

La correttezza empirica è stata testata sottomettendo una suite di interrogazioni mirate su casi reali estratti dall'A-Box, verificando che il motore inferenziale rispondesse in perfetto accordo con le specifiche clinico-comportamentali modellate:

Query Logica di Test	Output Atteso	Output Ottenuto	Stato del Test
misallineamento_circadiano(3, Mismatch). (<i>ID 3: Turnista con cronotipo neutral</i>)	Mismatch = moderato	Mismatch = moderato	Superato

tossicita_presonno(3, Livello). (ID 3: Caffeina 0mg, Alcol 2u, Screen 89 min)	Livello = alta (Score=3)	Livello = alta	Superato
stress_fisiologico(3, Livello). (ID 3: BMI 25, Sonno 3.74h, Cardio 72, Es 1)	Livello = critico (Score=5)	Livello = critico	Superato
genera_dataset_arricchito.	Generazione file CSV (100.000 righe)	Elaborazione completata con successo	Superato

Il test di performance sul processo di esportazione batch ha confermato l'efficienza computazionale dell'architettura: l'arricchimento logico massivo di tutti i 100.000 record del dataset avviene in pochi secondi con un utilizzo di memoria irrisorio, validando l'adozione del pattern basato sul fallimento programmatico per l'integrazione neuro-simbolica.

Capitolo 4

4. Apprendimento non supervisionato (k-means)

Sommario

Prima di procedere con i task predittivi, è stata condotta un'analisi di apprendimento non supervisionato al fine di esplorare la topologia dello spazio delle feature. L'obiettivo è scoprire l'esistenza di "fenotipi" latenti nel comportamento e nella fisiologia dei pazienti, raggruppandoli esclusivamente in base alle loro similarità intrinseche, senza fornire all'algoritmo alcuna informazione sulla diagnosi medica reale (target).

Strumenti utilizzati


Strumento/Libreria	Ruolo nel Sistema
K-means/Sklearn	Algoritmo di <i>hard clustering</i> basato sul calcolo delle distanze euclidee per la partizione dello spazio vettoriale.
PCA (Principal Component Analysis)/Sklearn:	Tecnica di riduzione dimensionale utilizzata per proiettare lo spazio multidimensionale in due componenti principali, permettendo la visualizzazione geometrica dei cluster.
Elbow Method:	Metrica euristica basata sulla minimizzazione della varianza intra-cluster (WCSS - <i>Within-Cluster Sum of Squares</i>) per determinare il numero ottimo di raggruppamenti.

Decisioni di progetto

Essendo il K-Means strettamente dipendente dalla scala spaziale delle variabili (distanza euclidea), il dataset è stato sottoposto a una rigorosa trasformazione:

- StandardScaler: Applicato a tutte le feature numeriche (es. heart rate, sleep duration) per centrare la media a 0 e scalare la varianza a 1, evitando che variabili con magnitudo maggiori dominassero il partizionamento.
- One-Hot Encoding: Applicato alle variabili categoriali per renderle conformi al calcolo spaziale.

Per evitare scelte arbitrarie sul numero di cluster, è stato calcolato il valore WCSS iterando l'algoritmo per K da 1 a 7. Come si evince dal grafico sottostante, il punto di "gomito" in cui il guadagno informativo marginale inizia a decrescere significativamente si attesta su **K=3**.




Valutazione dei Risultati

Una volta assegnati i pazienti ai 3 cluster, i risultati sono stati incrociati con il target clinico reale (sleep disorder risk), rivelando una buona capacità di separazione fenotipica.

Dal grafico PCA (a sinistra) si osserva una separazione spaziale netta dei tre cluster. Analizzando la distribuzione delle diagnosi reali all'interno di questi raggruppamenti (grafico a destra), emerge che l'algoritmo ha "riscoperto" autonomamente le classi mediche:

- Il Cluster 0 aggrega quasi esclusivamente i pazienti sani (Healthy).
- Il Cluster 1 e il Cluster 2 hanno catturato con successo le patologie (Mild e Severe), separando i profili di rischio basandosi unicamente su indicatori comportamentali e vitali, senza conoscerne l'etichetta.



Questo risultato certifica l'alta qualità informativa del dataset e valida l'ipotesi che lo stile di vita definisca firme biologiche nettamente distinguibili, preparando un terreno solido per il successivo addestramento supervisionato.

Capitolo 5

5. Apprendimento supervisionato (Machine Learning)

Sommario

Il modulo di apprendimento supervisionato costituisce la componente sub-simbolica e statistica del sistema intelligente. L'obiettivo primario consiste nel predire la classe di rischio legata ai disturbi del sonno del paziente (`sleep_disorder_risk`) a partire dalle sue caratteristiche fisiologiche e comportamentali.

Il focus metodologico di questo capitolo risiede nella validazione sperimentale del paradigma neuro-simbolico adottato. Piuttosto che addestrare i classificatori esclusivamente sui dati grezzi, il sistema implementa un benchmarking rigoroso volto a confrontare due diversi spazi di feature:

1. Solo Dati Grezzi (Baseline): I modelli apprendono esclusivamente dalle feature native rintracciabili nel dataset originale (es. età, ore di sonno, passi quotidiani, consumo di caffeina).
2. Dati + Prolog KB (Ibrido): Lo spazio delle feature viene arricchito iniettando le tre variabili latenti ad alto livello semantico estratte inferenzialmente dalla Knowledge Base nel Capitolo 3 (`misallineamento_circadiano`, `tossicita_presonno`, `stress_fisiologico`).

L'esperimento mira a dimostrare come l'introduzione di conoscenza strutturata a priori (background knowledge) consenta ai modelli statistici di raggiungere una migliore capacità di generalizzazione e confini di decisione più netti.

Strumenti utilizzati

Strumento / Libreria	Ruolo nel Sistema
Scikit-Learn (sklearn)	Framework principale per la costruzione delle pipeline di preprocessing, l'addestramento dei modelli e la validazione incrociata.
Decision Tree Classifier	Classificatore non parametrico basato su alberi di decisione, utilizzato come baseline di complessità computazionale minima.
Random Forest Classifier	Insieme di alberi di decisione (<i>Ensemble Learning</i>) basato sul principio del <i>bagging</i> , impiegato per mitigare l'overfitting e catturare relazioni non lineari robuste.
Support Vector Classifier (SVC)	Modello a scomposizione geometrica basato su macchine a vettori di supporto con supporto probabilistico abilitato (probability=True).
Stratified K-Fold	Tecnica di partizionamento dei dati a 5 fold che preserva la percentuale delle classi target in ogni split, garantendo valutazioni non distorte.

Decisioni di progetto

Separazione dei Dataset e Ingegneria delle Feature

Come implementato nel modulo `ml_pipeline.py`, il target `y` viene codificato numericamente tramite un `LabelEncoder` per normalizzare le stringhe delle classi in etichette discrete. La separazione dei predittori avviene isolando le colonne aggregate per via logica:

- **X_baseline:** Ottenuto escludendo l'identificativo del paziente (`person_id`), il target reale (`sleep_disorder_risk`) e le tre feature estratte da Prolog.
- **X_arricchito:** Mantiene la totalità delle feature di baseline, integrando come predittori addizionali le colonne `misallineamento_circadiano`, `tossicità_presonno` e `stress_fisiologico`.

Pipeline di Preprocessing Automatizzata

Per evitare il fenomeno del *data leakage* durante la validazione incrociata, il preprocessing viene incapsulato all'interno di un oggetto `Pipeline` combinato con un `ColumnTransformer`. Questo garantisce che i parametri di scaling e codifica vengano calcolati rigorosamente ed esclusivamente sui fold di addestramento (*train split*):

- **Feature Numeriche:** Trattate mediante standardizzazione (`StandardScaler`), che trasforma i dati in variabili a media nulla e varianza unitaria. Questa operazione è categorica e obbligatoria per garantire la convergenza geometrica dell'SVM.
- **Feature Categoricali (incluse le feature Prolog):** Trattate mediante codifica One-Hot (`OneHotEncoder(handle_unknown='ignore')`), che mappa i livelli qualitativi (es. *critico*, *severo*, *normale*) in vettori binari sparsi privi di arbitrarietà d'ordine.

Strategia di Validazione e Metriche di Prestazione

L'addestramento e il test avvengono mediante una `Cross-Validation Stratificata a 5 Fold` (`StratifiedKFold(n_splits=5, shuffle=True, random_state=42)`). La robustezza del comportamento dei tre modelli (`Random Forest`, `Decision Tree`, `SVM`) viene misurata simultaneamente attraverso tre metriche complementari:

- **Accuracy:** Misura globale della frazione di predizioni corrette.
- **F1-Macro:** Media aritmetica dei punteggi F1 calcolati in modo indipendente per ciascuna classe. È la metrica cruciale per valutare l'equità del modello in presenza di sbilanciamento delle classi.
- **Log-Loss (Entropia Incrociata):** Misura l'incertezza e la qualità delle probabilità calibrate restituite dai modelli (`neg_log_loss`). Valori più bassi indicano una maggiore confidenza del classificatore sulle risposte corrette.

Valutazione Sperimentale



Modello	Metrica	Solo Dati Grezzi (Baseline)	Dati + Prolog KB (Ibrido)
Decision Tree	Accuracy	89.81% $\pm$ 0.16%	89.84% $\pm$ 0.22%
	F1-Macro	79.32% $\pm$ 0.62%	79.42% $\pm$ 0.54%
	Log-Loss	1.2460 $\pm$ 0.0279	1.2387 $\pm$ 0.0391
Random Forest	Accuracy	86.98% $\pm$ 0.21%	86.56% $\pm$ 0.16%
	F1-Macro	75.37% $\pm$ 0.51%	74.55% $\pm$ 0.30%
	Log-Loss	0.3769 $\pm$ 0.0025	0.3887 $\pm$ 0.0014
SVM (Linear)	Accuracy	54.04% $\pm$ 3.39%	60.92% $\pm$ 2.68%
	F1-Macro	46.71% $\pm$ 1.84%	49.80% $\pm$ 2.18%
	Log-Loss	0.7848 $\pm$ 0.0294	0.7162 $\pm$ 0.0234


L'analisi comparativa rivela dinamiche interessanti che confermano la natura ibrida del sistema.

Confronto tra Modelli (Metriche)


Si osserva come l'impatto della Knowledge Base sia inversamente proporzionale alla complessità intrinseca del modello:

- SVM (Linear): Il modello beneficia enormemente dell'arricchimento (+6.88% di Accuracy), confermando che le feature semantiche offrono una separazione iperpianaria altrimenti irraggiungibile per un classificatore lineare.
- Decision Tree e Random Forest: Per questi modelli non-lineari, le feature Prolog introducono una ridondanza che porta a variazioni marginali o lievi decrementi. Ciò è fisiologico: essendo modelli capaci di apprendere relazioni complesse dai dati grezzi, il carico informativo aggiuntivo non incrementa ulteriormente le performance, ma conferma la stabilità della baseline.





Analisi dell'Importanza delle Feature



L'analisi della Feature Importance evidenzia come le variabili semantiche introdotte (Prolog) occupino posizioni di rilievo nel ranking delle variabili determinanti per il modello. È interessante notare come l'importanza sia distribuita: le feature Prolog non sostituiscono le variabili grezze, ma agiscono in sinergia con esse. La loro presenza permette al modello di catturare 'fenotipi' di rischio che, pur essendo correlati alle variabili native, vengono esplicitati in modo compatto tramite le regole inferenziali. Il fatto che variabili come stress_fisiologico siano presenti tra le feature rilevanti conferma che il contributo della Knowledge Base è significativo e integrato nel processo decisionale del classificatore.

Capitolo 6

6.Motore Probabilistico: Rete Bayesiana (BBN)

Sommario

Se il modulo di Machine Learning Supervisionato (Capitolo 4) garantisce un'elevata accuratezza predittiva, esso presenta il limite intrinseco di operare come una "scatola nera" (*black-box*). Al fine di implementare un vero e proprio ragionamento causale e di trasparenza decisionale (*Explainable AI*), l'architettura integra una **Rete Bayesiana Discreta (BBN)**.

La Rete Bayesiana permette di modellare l'incertezza del dominio medico attraverso la teoria della probabilità, quantificando le relazioni di causa-effetto tra le abitudini comportamentali, le feature latenti dedotte dalla Knowledge Base (Prolog) e il rischio clinico finale. Questa struttura consente al sistema di eseguire inferenze bidirezionali: sia predittive (dal comportamento al rischio) che diagnostiche (dal rischio alle cause scatenanti).

L'implementazione è stata realizzata in Python avvalendosi della libreria `pgmpy`, che fornisce astrazioni solide per la definizione dei grafi diretti e per l'esecuzione di algoritmi di inferenza esatta.

Strumenti utilizzati

Strumento	Ruolo nel Sistema
<code>pgmpy</code>	Libreria core per la modellazione probabilistica dell'IA. Fornisce la classe <code>DiscreteBayesianNetwork</code> per l'architettura del grafo, gestisce il calcolo automatico delle CPT e istanzia il motore di inferenza esatta.
<code>networkx</code>	Strumento per la creazione, manipolazione e studio strutturale dei grafi. Viene utilizzato per istanziare l'oggetto grafico diretto <code>DiGraph()</code> a partire dalle connessioni della rete e calcolarne il layout topologico.

<code>pandas</code>	Hub di preprocessing che si occupa dell'operazione di fusione (<i>merge</i>) tramite chiave interna <code>person_id</code> tra il dataset baseline (<code>sleep_health_dataset.csv</code>) e le feature latenti estratte dal Prolog (<code>sleep_health_enriched.csv</code>).
<code>numpy</code>	Libreria di calcolo matematico utilizzata per l'allineamento dei vettori di probabilità e il condizionamento delle matrici di fattori durante le fasi di computazione delle metriche prior/posterior.
<code>matplotlib & seaborn</code>	Librerie dedicate alla pipeline di visualizzazione per la renderizzazione del DAG e la generazione automatica dei grafici comparativi delle distribuzioni probabilistiche.

Decisioni di progetto

Struttura del Grafo Diretto Aciclico (DAG)

La topologia della rete definisce le relazioni di causa-effetto stabilite a livello di progettazione medica. Il DAG implementato nel codice non è appreso strutturalmente dai dati, ma risponde a precisi vincoli causali di dominio, formalizzati nel costruttore di `DiscreteBayesianNetwork` mediante tre archi orientati fondamentali:

- **tossicita_presonno** → **stress_fisiologico**: Le abitudini comportamentali scorrette (abuso serale di sostanze e schermi) alterano direttamente i parametri omeostatici e biologici del soggetto.
- **stress_fisiologico** → **sleep_disorder_risk**: Lo scompenso dei parametri fisiologici e biometrici agisce come causa primaria nell'insorgenza del disturbo clinico.
- **misallineamento_circadiano** → **sleep_disorder_risk**: Il conflitto tra i turni di lavoro e il cronotipo biologico costituisce un fattore di rischio indipendente e diretto per la qualità del sonno.

Discretizzazione delle Variabili Continue

Un'elegante peculiarità ingegneristica di H.Y.P.N.O.S. risiede nella pulizia del codice di preprocessing della BBN. Molto spesso le Reti Bayesiane richiedono pesanti operazioni

algoritmiche di *binning* o discretizzazione numerica arbitraria (*K-Means binning*, *Equal Width*, *Equal Frequency*) immediatamente prima del training.

In questo framework, tale compito è interamente delegato a monte alla **Knowledge Base in Prolog (Capitolo 3)**. Le regole intensionali della T-Box hanno già categorizzato le metriche continue del dataset in stringhe discrete e semantiche (severo, critico, alta, normale). Lo script Python si limita quindi a selezionare tali colonne dal dataframe arricchito, a rimuovere eventuali valori nulli e a castarle come stringhe native (`.astype(str)`), garantendo una perfetta convergenza tra lo strato logico e quello probabilistico.

Apprendimento dei Parametri e Analisi sullo Stimatore BDeu

Una volta definita la struttura del grafo, la rete deve quantificare la forza dei legami tramite le Tabelle di Probabilità Condizionata (CPT). Il codice esegue il training invocando il metodo `.fit(dati_bbn)`.

In fase di progettazione è stata valutata l'adozione di uno stimatore bayesiano basato su priori **BDeu (Bayesian Dirichlet equivalent uniform)**, configurazione tipica nei contesti con scarsità di dati per evitare probabilità nulle (*zero-frequency problem*). Tuttavia, l'elevata cardinalità dello *Sleep Health Dataset* (100.000 record completi) fornisce un campione statistico eccezionalmente denso per ogni combinazione di stato. Di conseguenza, si è optato per lo stimatore di default di pgmpy, ovvero il **Maximum Likelihood Estimator (MLE)**. Con 100.000 istanze a disposizione, le frequenze relative calcolate tramite MLE convergono perfettamente verso le reali probabilità della popolazione, eliminando il rischio di distorsioni (*bias*) che l'introduzione di un priore artificiale BDeu avrebbe inevitabilmente comportato.

Inferenza a RunTime: Variable Elimination

Per l'interrogazione del modello a runtime è stato selezionato l'algoritmo di inferenza esatta **Variable Elimination**. Poiché il calcolo della probabilità marginale in una rete bayesiana è un problema NP-hard se affrontato per enumerazione esaustiva, la Variable Elimination ottimizza il processo fattorizzando la distribuzione congiunta globale.

L'algoritmo distribuisce le sommatorie all'interno dei singoli fattori ed elimina (marginalizza) sequenzialmente le variabili non facenti parte della query o delle evidenze. Data la struttura snella e aciclica del nostro DAG, l'inferenza esatta viene eseguita in tempo lineare, garantendo responsività immediata quando il pianificatore A* interroga la rete come oracolo probabilistico.

Valutazione e Analisi dei Grafici

La validazione della Rete Bayesiana è stata eseguita verificando la coerenza logico-matematica delle risposte inferenziali fornite dal modello a fronte di scenari clinici reali e analizzando la convergenza empirica con le distribuzioni del dataset.

L'analisi del comportamento del modello evidenzia una notevole coerenza clinica: a fronte di fattori di rischio massimi, la probabilità di essere completamente sani (**Healthy**) crolla al 10.27%. Il modello non si limita a saltare ciecamente verso la classe peggiore (**Severe**), ma distribuisce accuratamente la massa probabilistica, individuando nella classe **Mild** il picco relativo (43.84%). Questo comportamento riflette i confini sfumati e non lineari del dataset da 100.000 record, catturando la transizione progressiva del rischio biologico.





Grafico a barre raggruppate (Prior vs Posterior). L'istogramma mostra visivamente lo spostamento della densità di probabilità: la baseline della popolazione (Prior blu) viene rimodellata dall'evidenza clinica (Posterior verde), penalizzando la classe Healthy e innalzando i vettori di rischio.

Validazione Topologica del Modello

All'avvio del modulo, la chiamata a `modello_bayes.check_model()` ha superato con successo la verifica formale. Questo garantisce che il Grafo Diretto Aciclico (DAG) sia esente da cicli orientati chiusi e che tutte le Tabelle di Probabilità Condizionata (CPT) apprese tramite lo

stimatore di massima verosimiglianza siano stocasticamente consistenti (ovvero che la somma delle probabilità per ogni riga sia esattamente pari a 1.0).



Struttura del Grafo Diretto Aciclico (DAG) esportata nella directory dei grafici. L'immagine evidenzia visivamente l'architettura dei nodi e le relazioni di dipendenza causale che collegano le variabili intermedie al target finale.

Scenario 1: Inferenza Predittiva (What-If Analysis)

Il primo test di runtime simula un'interrogazione "in avanti" (*forward reasoning*) per valutare l'effetto di un quadro clinico e lavorativo fortemente deteriorato. È stata inserita un'evidenza deterministica che mappa un soggetto in forte stress biologico e con ritmi circadiani alterati dai turni lavorativi:

Evidence = {*stress_fisiologico*: 'critico'}, *text*{*misallineamento_circadiano*: 'severo'}

L'algoritmo di *Variable Elimination* ha calcolato la seguente distribuzione di probabilità posteriore per la variabile obiettivo $P(\text{sleep_disorder_risk} \mid \text{Evidence})$:

Classe Target (sleep_disorder_risk)	Probabilità Posteriore (ϕ)

Healthy	0.1027 (10.27%)
Mild	0.4384 (43.84%)
Moderate	0.2544 (25.44%)
Severe	0.2045 (20.45%)

Scenario 2: Inferenza Diagnostica (Ragionamento all'Indietro)

Per validare la capacità della rete di operare come strumento diagnostico ed esplicativo (*Root Cause Analysis*), è stata iniettata come evidenza la condizione di perfetta salute del paziente, chiedendo al motore inferenziale di calcolare a ritroso la distribuzione della causa scatenante comportamentale:

Evidence = {*sleep_disorder_risk*: 'Healthy'}

Query = P(tossicità_presonno | Evidence)

L'interrogazione ha prodotto il seguente profilo probabilistico:

Stato della Variabile (tossicità_presonno)	Probabilità Posteriore (ϕ)
alta	0.5745 (57.45%)
bassa	0.3085 (30.85%)
critica	0.1170 (11.70%)

A prima vista, il fatto che un paziente sano presenti una probabilità del 57.45% di avere una tossicità pre-sonno "alta" potrebbe apparire controintuitivo. Tuttavia, l'analisi matematica dei dati reali dimostra la straordinaria fedeltà della Rete Bayesiana nel catturare la struttura del dataset di addestramento. Controllando la distribuzione globale (*Prior empirico*) della tossicità nel dataset originario, emerge infatti che la classe alta è fortemente predominante in tutta la popolazione:

- alta: 57.71%
- bassa: 30.45%
- critica: 11.84%

L'analisi della tabella di contingenza incrociata (*cross-tabulation*) estratta direttamente dai dati conferma che, anche isolando i soli soggetti sani (Healthy), le proporzioni reali specchiano quasi matematicamente l'output della rete:

sleep_disorder_risk	Healthy	Mild	Moderate	Severe
tossicità_presonno				
alta	0.571959	0.585143	0.578503	0.576242
bassa	0.338762	0.274739	0.247620	0.209543
critica	0.089279	0.140118	0.173876	0.214215

Il modello probabilistico si è dimostrato efficace: ha appreso che la tossicità "alta" è una costante di sfondo diffusa nel campione a causa dello stile di vita moderno generato sinteticamente (es. uso pervasivo di schermi). Ciononostante, la rete cattura il corretto gradiente causale penalizzando la tossicità critica (che scende dall'11.84% globale all'11.70% tra i sani, toccando il valore minimo assoluto dell'8.9% nei dati puri dei soggetti esenti da disturbi) e premiando la tossicità bassa.

Questo comportamento valida l'affidabilità della BBN a runtime: le risposte riflettono con assoluto rigore matematico le probabilità condizionate del mondo reale codificato nel dataset, rendendo la rete adatta per guidare le euristiche di costo dell'algoritmo di ricerca A*.

Capitolo 7

7. Ricerca Euristica: Algoritmo A*

Sommario

Il modulo di pianificazione clinica è il motore decisionale centrale del progetto. Prende in ingresso il profilo vettoriale corrente del paziente (composto da 8 metriche fisiologiche e comportamentali) e produce il piano terapeutico ottimizzato: la sequenza di modifiche allo stile di vita a costo minimo che permetta al paziente di rientrare in una fascia di rischio clinico sicura. Il problema viene formulato come ricerca del cammino a costo minimo in uno spazio degli stati multidimensionale, le cui transizioni sono governate da un set di azioni terapeutiche predefinite (es. limitare la caffeina, aumentare le ore di sonno). Si tratta di un'esplorazione mirata: dato un profilo patologico, trovare la combinazione di azioni con il minor impatto psicofisico capace di ripristinare l'omeostasi del sonno.

L'algoritmo impiegato è l'A*, che ordina la frontiera di ricerca secondo la funzione $f(n) = g(n) + h(n)$, combinando il costo reale cumulato $g(n)$ con la stima euristica della distanza rimanente dallo stato di salute $h(n)$. Utilizzare algoritmi di ricerca non informata come BFS o DFS non sarebbe stato praticabile in uno spazio di stati quantizzato a 8 dimensioni: occorre individuare non una terapia qualsiasi, ma quella ottimale (più tollerabile) per il paziente. Come dimostrato dalla teoria, A* garantisce l'ottimalità della prima soluzione trovata purché l'euristica sia ammissibile, ovvero non sovrastimi mai lo sforzo reale rimanente.

Strumenti Utilizzati

Strumento	Versione	Ruolo nel Sistema
heapq (stdlib Python)	—	Implementazione della Priority Queue (min-heap) per gestire la frontiera (<i>Open Set</i>) di A^* , estraendo il nodo a minimo $f(n)$.
math (stdlib Python)	—	Calcolo algebrico della radice quadrata e delle potenze per l'euristica basata sulla distanza Euclidea vettoriale.

pgmpy (VariableElimination)	\ge 0.1.x	Motore di inferenza della Rete Bayesiana (BBN) utilizzato dinamicamente come <i>Goal Test</i> per validare lo stato di salute.
pandas	Standard	Costruzione al volo dei DataFrame (con nomi colonna normalizzati) in caso di interrogazione del classificatore ML (Random Forest).

Il motore logico è incapsulato nella funzione `plan_therapeutic_path()`. Le funzioni `is_healthy_bbn` e `is_healthy_ml` gestiscono l'interfaccia ibrida con i modelli di Intelligenza Artificiale per decretare l'arresto della ricerca, fungendo da oracoli di validazione probabilistica.

Decisioni di Progetto

Spazio degli Stati

Ogni nodo dello spazio di ricerca è una tupla a 8 dimensioni rappresentante l'esatto quadro clinico e comportamentale del paziente in quel momento:

(bmi, caffeina, steps, sleep, caf_bed, alc_bed, screen, temp)

Lo stato iniziale corrisponde al profilo di input. Il *goal* non è un nodo statico predefinito, ma qualsiasi stato che soddisfi le condizioni dettate dal modello probabilistico (Rete Bayesiana). L'espansione di un nodo applica l'array di dizionari ACTIONS, generando un successore per ogni azione valida. La visita usa un dizionario best_g_scores che associa ogni stato espanso al suo costo g minimo raggiunto, implementando la ricerca su grafo per potare istantaneamente le ri-espansioni sub-ottimali.

Funzione di Costo Reale g(n)

Il costo g(n) è puramente additivo e rappresenta lo sforzo psicologico e biologico (*Aderenza Terapeutica*) richiesto al paziente per attuare un cambiamento.

Le penalità sono predefinite all'interno delle ACTIONS. Ad esempio, le correzioni ambientali passive ("Regola il termostato") hanno un costo quasi nullo (4), l'estensione del riposo ha un costo basso (5), mentre sradicare abitudini sociali ("Riduci alcol a cena") costa 18 e intraprendere una dieta rigida per variare il BMI costa 25. Questo dislivello quantitativo fa sì che A* esaurisca prima tutte le vie a bassa resistenza, proponendo le terapie d'urto solo come *extrema ratio*.

Euristica Ammissibile h(n)

La funzione heuristic(state) calcola lo scostamento rimanente verso i target fisiologici ottimali (es. BMI 24.9, Caffaina serale 0mg, Screen Time ≤ 30 min, Temperatura 18.5°C).

Trattandosi di metriche su scale profondamente diverse, l'euristica adotta una Distanza Euclidea Normalizzata, dividendo il delta di ogni variabile per un fattore di scala specifico (es. SCALE_STEPS = 5000.0, SCALE_TEMP = 5.0).

La metrica calcola solo gli scostamenti penalizzanti (tramite max(0.0, ...), tranne per la temperatura calcolata in valore assoluto). Questa funzione costituisce un rilassamento del problema reale: la distanza in linea d'aria normalizzata non sovrastima mai la somma dei costi delle singole azioni discrete (che valgono dai 4 ai 25 punti di penalità g), mantenendo la proprietà di ammissibilità fondamentale per A*.

Goal Test Ibrido (Interazione Neuro-Simbolica)

A differenza dei classici algoritmi pathfinding, il test obiettivo non confronta le tuple. La funzione is_healthy_bbn(state) agisce da ponte:

1. Converte le variabili continue del nodo corrente nelle astrazioni semantiche richieste dalla BBN (tossicità, stress, misallineamento).
2. Interroga la Variable Elimination di pgmpy.
3. Se $P(\text{sleep_disorder_risk} = \text{'Healthy'}) \geq 0.80$, la ricerca si ferma e dichiara il successo.

In alternativa, il codice prevede il fallback is_healthy_ml che valuta il vettore tramite .predict_proba() del classificatore ML con soglia 0.85, garantendo modularità al sistema.

Valutazione

La correttezza di A^* è garantita analiticamente dalla teoria della ricerca euristica. La valutazione del nostro planner si articola sulla verifica formale delle proprietà algoritmiche e sulla validazione dell'output di esecuzione su un caso clinico severo.

Verifica delle Proprietà Formali

Proprietà	Condizione	Verifica nell'Implementazione
Ammissibilità dell'euristica	$h(n) \leq h(n)$ per ogni nodo	La distanza euclidea normalizzata calcola scarti frazionari (spesso < 1.0), rimanendo sempre strettamente inferiore al costo reale di step terapeutici minimi ($g \geq 4$).
Completezza	Se esiste una soluzione, A^* la trova	La frontiera gestita tramite min-heap esplora in modo esaustivo tutti i percorsi non dominati.

Ottimalità	La prima soluzione estratta è la migliore	Garantita dalla teoria, dato che il costo degli archi è strettamente positivo e $h(n)$ è ammissibile.
Pruning Graph-Search	Non si espandono stati peggiori già visti	if $g >$ <code>best_g_scores.get(...)</code> salta il ciclo e pota il ramo, prevenendo loop infiniti.
Coerenza Dinamica del Goal	L'obiettivo ha valenza medica reale	Validato inferenzialmente a runtime dalla BBN tramite la query probabilistica ≥ 0.80 .

Casi di Test Funzionali (Log di Esecuzione)

Scenario Iniziale	Terapia Attesa	Esito e Azioni Eseguite (A*)
-------------------	----------------	------------------------------

Paziente Critico (Sonno 5.0h, Caffeina Pre-sonno 60mg, Temp 23.5°C, Screen 120m)	Ottimizzazione passiva del sonno e taglio drastico degli stimolanti serali prima di toccare l'alcol.	Convergenza in 7 Step ottimali. Step 1-4: Estensione sonno a 7.0h (+30m iterativi, costo minimo). Step 5-7: Taglio caffeina serale a 0mg (-20mg iterativi). L'alcol (costo 18) non viene toccato.
---	---	--

Parametri e Soglie

Parametro	Valore	Motivazione Clinica / Algoritmica
threshold BBN	0.80 (80%)	Soglia di sicurezza medica. Il paziente ha probabilità predominante di non sviluppare insonnia.
Costo azione Temp	4	Modifica ambientale istantanea (Termostato). Minor resistenza psicologica.
Costo azione Alcol	18	Barriera comportamentale e sociale alta. L'algoritmo la applica solo se strettamente necessario.

Costo azione Dieta	25	Sforzo metabolico a lungo termine. Massima penalizzazione per favorire l'igiene del sonno.
SCALE_SCREEN	120.0	Evita che ampie variazioni temporali in minuti dominino erroneamente sull'euristica totale.
Fallback BBN Exception	Condizioni booleane rigide	Se la rete fallisce, il sistema ripiega su vincoli <i>hard-coded</i> per garantire continuità di servizio.

8. Conclusioni

Nel complesso, il framework funziona come previsto e centra appieno gli obiettivi architetturali prefissati. L'integrazione fluida tra la componente simbolica (Knowledge Base), statistica (Machine Learning) e probabilistica (Rete Bayesiana) produce risultati coerenti con le aspettative della medicina del sonno.

Il modulo di pianificazione A* trova sempre la soluzione ottimale rispetto alla funzione di costo (minimizzando lo sforzo psicofisico del paziente), la Knowledge Base in Prolog assegna dinamicamente i costi e funge da scudo contro prescrizioni comportamentali incompatibili, e la

Rete Bayesiana garantisce che l'algoritmo si fermi solo quando la probabilità di guarigione supera la soglia di sicurezza. I casi di test coprono gli scenari principali e dimostrano come il sistema favorisca sempre interventi ambientali a basso costo (es. termostato) prima di scalare verso restrizioni sociali o dietetiche severe (es. alcol o riduzione marcata delle calorie).

Un esempio di esecuzione sul terminale è riportato di seguito

```
=====
A* CLINICAL PLANNER: MODELLO AD 8 VARIABILI
=====
[RUN]: Ricerca del percorso terapeutico ottimale tramite BBN...
Stato Iniziale Paziente:
-> BMI: 23.5 | Caffè Giornaliero: 150mg | Passi: 13500 | Sonno: 5.0h
-> Caffè Pre-Sonno: 60mg | Alcol Sera: 2 u | Screen Time: 120m | Temp
Stanza: 23.5°C

=====
PIANO DI IGIENE DEL SONNO E DELLO STILE DI VITA TROVATO
=====
Step 1: Migliora l'igiene del sonno (+30 min di riposo)
-> Stato: Sonno=5.5h
Step 2: Migliora l'igiene del sonno (+30 min di riposo)
-> Stato: Sonno=6.0h
Step 3: Migliora l'igiene del sonno (+30 min di riposo)
-> Stato: Sonno=6.5h
Step 4: Migliora l'igiene del sonno (+30 min di riposo)
-> Stato: Sonno=7.0h
Step 5: Elimina caffè/te pomeriggio o serale (-20mg pre-sonno)
-> Stato: CaffèSera=40mg
Step 6: Elimina caffè/te pomeriggio o serale (-20mg pre-sonno)
-> Stato: CaffèSera=20mg
Step 7: Elimina caffè/te pomeriggio o serale (-20mg pre-sonno)
-> Stato: CaffèSera=0mg
Stato Finale Validato dalla Rete: (23.5, 150, 13500, 7.0, 0, 2, 120,
23.5)
```

Sviluppi Futuri e Limitazioni Attuali

Sviluppi Futuri

1. **Integrazione Dati Real-Time (IoT e Wearables):** Attualmente il sistema valuta snapshot statici. Un'evoluzione naturale prevede il collegamento tramite API a dispositivi indossabili (es. smartwatch, anelli per il tracciamento del sonno) per aggiornare automaticamente metriche come i passi e il battito cardiaco, e a sistemi domotici per rilevare e regolare dinamicamente la temperatura della stanza.
2. **Ontologia Formale (OWL):** La Knowledge Base è attualmente implementata in Prolog nativo. L'estensione verso un'ontologia formale basata su standard W3C (come OWL) permetterebbe la condivisione della conoscenza medica e la piena interoperabilità del sistema con i fascicoli sanitari elettronici (es. standard HL7/FHIR).
3. **Azioni Parametriche Continue:** Nel modulo di pianificazione attuale, le azioni hanno step incrementali fissi (es. -20mg di caffeina, +30 minuti di sonno). Consentire ad A* di istanziare variazioni parametriche continue permetterebbe di generare piani terapeutici ancora più fluidi e ritagliati millimetricamente sul paziente.

Limitazioni Attuali

1. **Discretizzazione e Perdita di Informazione:** La Rete Bayesiana (BBN) richiede in input variabili discrete. Nonostante la mappatura semantica effettuata dal Prolog sia solida, il raggruppamento di variabili continue (come i minuti di screen time) in "bin" qualitativi (bassa, alta, critica) comporta un'inevitabile perdita di granularità statistica.
2. **Indipendenza delle Variabili nelle Transizioni:** Nel simulatore A*, l'effetto di un'azione modifica una singola variabile assumendo che le altre restino inalterate. In realtà, la biologia umana è profondamente interconnessa: un aumento drastico dell'attività fisica potrebbe temporaneamente alterare il battito cardiaco a riposo o la percezione termica. Il modello attuale non cattura esplicitamente questi feedback loop incrociati.

9. Riferimenti Bibliografici

[1] *Dispense del corso ICon — Ingegneria della Conoscenza, A.A. 2025–2026, Università degli Studi di Bari Aldo Moro.*

[2] *Artificial Intelligence: Foundations of Computational Agents (3rd edition) David L. Poole, Alan K. Mackworth Cambridge University Press, 2023*

[3] *Russell, S. J., & Norvig, P. (2021). Artificial Intelligence: A Modern Approach (4th ed.). Pearson.*

[4] **Irish, L. A., Kline, C. E., Gunn, H. E., Buysse, D. J., & Hall, M. H. (2015).** The role of sleep hygiene in promoting public health: A review of empirical evidence. *Sleep Medicine Reviews*, 22, 23-36.

[5] **Garcez, A. d'Avila, et al. (2022).** Neurosymbolic AI: The 3rd wave. *Artificial Intelligence Review*, 55(6), 4511-4526.

[6] **Fenton, N., & Neil, M. (2018).** Risk Assessment and Decision Analysis with Bayesian Networks (2nd ed.). CRC Press.

[7] **Khosla, S., et al. (2020).** Machine learning in sleep medicine: clinical potential and challenges. *Sleep*, 43(6), zsaa018.

[8] **Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011).** Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

[9] **Breiman, L. (2001).** "Random Forests." *Machine Learning*, 45(1), 5-32.